

結合社群媒體情緒與互動指標預測電影評分與全球票房： 不同機器學習模型之比較研究

Predicting Film Ratings and Global Box Office Revenues Using Social Media Sentiment and Engagement Metrics: A Comparative Study of XGBoost and Random Forest Models

Group F

組員：周知顯、盧仁宇、曾鈺淇、周芷茵、許珈寧、胡馨云

指導教師：何承遠

摘要

隨著社群媒體上輿論的影響日益提升，本研究探討利用 Twitter 上的電影評論進行情緒分析，是否能有效預測電影評分與全球票房表現。研究動機源自近期如白雪公主真人版等作品在上映前即引發大量討論，促使我們思考社群輿論是否能成為預測依據。首先透過 Twikit 套件進行爬蟲，蒐集相關推文並以預訓練之 BERT 模型(基於 GoEmotions 資料集)進行情緒判讀，擷取 28 種情緒指標。接著，結合推文發佈者之粉絲數、按讚數、轉推數等互動指標，整合成特徵資料集。最後利用不同的機器學習模型進行訓練，以預測 Rotten Tomatoes、IMDb 評分與全球票房收入。實驗結果顯示 Gradient Boosting 模型整體表現最佳， R^2 與 RMSE 分數優於其他模型，雖 R^2 分數不顯著，但測試集的預測誤差小(誤差 0.33 以內/總分 1 到 10)。研究證實社群情緒分析可一定程度上反映觀眾觀感，並提供片商實務上的早期觀眾反應監測與行銷優化建議。未來將拓展至多平台、多語言資料、區域市場切分與使用者屬性特徵，以提升預測準確性與模型穩定性。

壹、 簡介

一、 研究動機

利用機器學習分析推特上電影評論貼文之情緒，來達到預測該部電影評分的目的。近期迪士尼白雪公主真人版電影上映，因為主角的膚色與矮人重現的方式沒有完全符合大眾期待，因此有許多不同的聲音，使得官方關閉了評論。這讓我們想要進一步探討，社群媒體上有關於特定電影的評價，是否能做更深入的分析並作為評分和票房的預測基準。

二、 研究方法

我們先使用第三方的 Twikit 連接 Twitter API，設定搜尋條件後在 X 平台上用爬蟲擷取多部電影評論，將其放入 pre-train 完的 BERT 模型去分析 27 種情緒的參

數，取其中重要性較高者放入不同模型，比較在不同模型中評分和票房的預測準確性。

三、研究貢獻

透過社群媒體上電影相關推文的情緒分數與互動指標，構建迴歸模型並驗證網路聲量與情緒對票房與評價的預測能力。本研究的主要貢獻在於分析評論以預測票房，預計可以幫助業者了解評分與真實市場是否有相同的聲音，提供一套可擴展至不同電影、新增社群特徵的通用框架，對於電影行銷與市場分析具有實務參考價值。

貳、 相關文獻探討

一、 Emotion Prediction App


在本研究中，我們首先參考了 Rakesh Sahni B.E. 所開發並發佈於 GitHub 上的 *Emotion Prediction App*。該專案結合了機器學習與深度學習技術，用以執行基於文字的情緒分類。

在機器學習階段，他使用了 Bernoulli Naive Bayes 模型，並透過 CountVectorizer 與 TF-IDF 提取文字特徵，同時使用 spaCy 進行文字預處理（例如斷詞、去除標點符號與停用詞）。此模型將每筆輸入文字分類為四種情緒之一：喜悅（joy）、悲傷（sadness）、憤怒（anger）或恐懼（fear）。在深度學習階段，Sahni 採用了 LSTM（Long Short-Term Memory，長短期記憶）遞迴神經網路模型，並利用 GloVe 預訓練詞向量來表示輸入文本，整體架構則基於 TensorFlow 深度學習框架。此模型輸出六類情緒的機率分布，包括：喜悅、悲傷、憤怒、恐懼、愛（love）與驚訝（surprise）。

雖然 Sahni 的模型同樣以 GoEmotions 資料集進行訓練，但僅涵蓋其中六類情緒；而我們的研究則採用了完整的 GoEmotions 分類體系，共包含 27 種細緻情緒加上中性（neutral），使得情緒分析更具細緻性與全面性。受到 Sahni 所提出多標籤機率輸出形式的啟發，我們同樣採用了基於機率的情緒分布方式。不過，我們的方法進一步導入了預訓練的 BERT 語言模型，並透過 HuggingFace Transformers 與 PyTorch 實作，於準確率與語意理解層面皆優於 LSTM。此模型能夠更細膩地解析複雜自然語言中的情緒，例如電影評論中所呈現的情感表達。

二、 BERT 模型

我們使用 BERT (Bidirectional Encoder Representations from Transformers) 模型來分析文本，此方式是 Google 在 2019 年所發表的。



BERT 是基於 transformer 架構的深度雙向預訓練模型，通過大規模的無監督式學習，學習豐富的語言表示，分為兩階段，分別是預訓練 (Pre-training) 與微調 (Fine-tuning)。兩者區別在於預訓練會在無標記的資料上進行，而微調則是在特定標記的資料上進行。

1. 預訓練 (Pre-training)

會通過遮罩語言模型 (Masked Language Model, MLM) 與下一個句子預測 (Next Sentence Prediction, NSP) 兩個無監督任務來從無標記文本中學習通用語言表示。這兩個模型的使用，使得深度雙向編碼器架構能夠形成。

(1.) 遮罩語言模型 (Masked Language Model, MLM)

隨機遮罩 (mask) 會輸入序列中的一部分詞 (token)，然後模型的目標是基於其語境來預測這些被遮罩詞的原始詞彙 ID

詳細步驟如下：

- 每個序列中會隨機選擇 15% 的 WordPiece token 進行遮罩。
- 被選擇的 token 有 80% 的機率被替換成 [MASK] token，10% 的機率被替換成一個隨機的 token，還有 10% 的機率保持不變。
- 對應於被遮罩 token 的最後隱藏向量會被送入一個輸出 softmax 層，以預測原始的 token，softmax 可以把輸入的內容映射到 0-1 之間。

這是一張用一些數學去解釋 Softmax layer 的圖示，我們將概念簡化成：我們希望拿到分值大的資料，但同時也希望有少部分機率去取到分值小的數據，因此我們運用 soft 的概念，輸出每個分類被取到的概率。

(2.) 下一個句子預測 (Next Sentence Prediction, NSP)

訓練模型理解兩個句子之間的關係，讓問答與自然語言推理能夠發生

- 每個預訓練樣本，會抽取兩個句子 A 和 B

- ii. 句子在 50% 的情況下，B 是 A 之後的實際下一個句子 (標記為 IsNext)，另外 50% 的情況下，B 是從語料庫中隨機抽取的句子 (標記為 NotNext)
- iii. 模型需要預測 B 是否是 A 的實際下一個句子。這個預測使用了特殊標記 [CLS] 對應的最後隱藏向量，即 **classification** 的意思，用於下游的分類任務

2. 微調 (Fine-tuning)

在預訓練完成後，BERT 模型會使用預訓練的參數進行初始化。然後，使用特定於下游任務的**標記資料來微調所有參數**，來符合實際應用需求。通常每個下游任務都有一個單獨微調的模型。微調階段需要的任務特定架構修改非常少，通常只需要在預訓練的 BERT 模型之上增加一個額外的輸出層。

參、 資料說明

一、 爬蟲輸出資料

使用者資訊部分包含推文發表者的帳號基本資料，例如用戶的唯一識別碼 (User ID)、顯示名稱 (User Name)、粉絲人數與關注人數，以及帳號是否經過官方認證。這些資訊有助於衡量使用者在社群中的影響力，亦可用於後續將推文影響程度與發文者身份特徵作交叉分析。

推文內容則涵蓋每則推文的完整文字內容、語言類型與發佈時間等欄位。由於搜尋條件中限定語言為英文，因此所取得的內容具備語言一致性，便於後續進行情感分析或文字分類任務。

互動指標部分則記錄了每則推文的參與度表現，包括按讚數 (favorites)、轉推數 (retweets)、回覆數 (replies) 以及被引用轉推的次數 (quotes)。這些指標可用來評估推文的社群擴散力與受歡迎程度。

所有資料以 CSV 格式儲存，檔名以時間戳命名，確保每次蒐集結果可區分、可追蹤，同時避免覆蓋先前的紀錄。CSV 作為結構化資料格式之一，亦具備良好的可讀性與跨平台相容性，能方便地匯入至各類數據分析工具中使用。

二、 情緒分析資料

情緒分析的資料是接續爬蟲結果所產生的延伸資料。我們會根據每則推文的文字內容，進行情緒判斷，並將結果直接加回原本的資料表中。程式會判定推文的 28 種不同的情。每種情緒都有對應的欄位，標示在這則推文中各種情緒的機率。

處理後的情緒分析結果會與原始爬蟲資料整合在同一個 CSV 檔案中，讓整份資料既保有原始內容，也多了情緒面的資訊。這樣的格式不但方便之後匯入各種數據分析工具，也有利於進行後續的分析。

肆、 研究方法

一、 爬蟲

首先，在資料蒐集階段，本研究使用 Python 編寫爬蟲程式，並採用第三方函式庫 `twikit` 作為與 Twitter/X 平台互動的工具。登入程序透過讀取事先儲存的 `Cookie` 檔案來完成，以省去每次重新驗證的麻煩。為了提升執行效率並減少阻塞，本程式採用了 Python 的非同步編程架構（`asyncio`），能同時處理多筆請求。爬蟲執行時使用一組明確定義的搜尋條件進行查詢，包含設定推文語言為英文、排除含有外部連結的推文、並限定推文至少獲得十個喜歡。此舉有助於篩選出具代表性、內容完整且具參與度的評論資料。

在資料篩選完成後，進一步進行預處理作業。這包括統一欄位格式、轉換時間戳記為標準時間格式、以及將互動指標轉為整數型態。同時，也會過濾掉無效、重複或空白內容，以確保資料整潔與一致性。

為了使程式具備穩定性與自我修復能力，系統亦內建錯誤處理邏輯。當遇到 Twitter API 的速率限制錯誤（`TooManyRequests`）時，程式會解析 API 回傳的限制重設時間，自動暫停作業並等待至限制解除後再繼續執行。這項設計確保了程式能在無人監控的情況下長時間穩定運作，亦不會違反平台的使用規範。

最後，本研究預留了多項應用方向作為後續擴展的基礎。例如可進行情感分析，判斷推文為正面、負面或中性情緒；亦可實施主題建模，提取評論中重複出現的關鍵主題；更可以進行時間序列分析，觀察不同時段內評論熱度的變化趨勢。這些應用皆建立於本研究所構建的穩定且高品質的資料蒐集流程之上。

二、 情緒分析

我們使用的模型是 BERT，是一種非常強大的深度學習語言模型。版本是 HuggingFace 提供的 `bert-base-go-emotion`，這個模型已經在 Google 的 GoEmotions 資料集上訓練好，能夠辨識 27 種細緻的情緒，加上中性（`neutral`），並為每一種情緒的多寡打分數，而不是只將一句話歸類為一種情緒。

首先用 `pandas` 讀取前面爬蟲的結果，裡面每列都有一則電影評論。接著一行一行預測文字的情緒，使用 BERT 模型，以及 BERT 內建的 `tokenizer`，將每一則文字輸入轉換成模型能夠理解的格式。經過轉換後的資料會送進 BERT 模型進行預測，取得每一種情緒對應的機率分數。最後把這些機率結果，存入新的 CSV 檔案，提供給評分預測使用。

使用工具：


1. 使用 `transformers` 載入 BERT 模型與 `tokenizer`
2. **PyTorch** 套件主要扮演「深度學習框架」的角色，也就是說，**PyTorch** 提供了實作、訓練與推論 BERT 模型所需的一切工具和底層機制。這個框架將

torch 中高效而靈活的 GPU 加速後端庫與直觀的 Python 前端相結合，支持盡可能廣泛的深度學習模型。

3. 使用 pandas 來處理 csv 資料

技術架構：

```
label 為 27+1 種情緒 (labels = [  
    "admiration", "amusement", "anger", "annoyance", "approval", "caring",  
    "confusion", "curiosity", "desire", "disappointment", "disapproval",  
    "disgust", "embarrassment", "excitement", "fear", "gratitude", "grief",  
    "joy", "love", "nervousness", "optimism", "pride", "realization", "relief",  
    "remorse", "sadness", "surprise", "neutral"  
])。
```



三、評分預測

1. data_with_ratings.csv 資料集測試

首先載入前面情緒分析後的資料集，資料中每筆推文已具備情緒分數、每部電影的名稱、IMDb 評分，以及使用者 id、點讚數等欄位。

先進行 28 種情緒特徵對評分 (rating) 的迴歸建模。此步驟可反推出各情緒對評分的貢獻權重，並建立一條公式，作為模擬評分的生成依據。再來藉由 sklearn 的 Random Forest Regressor 模型，得到每種情緒在評分預測中的重要性，只留下重要性大於 0.035 的情緒，篩選後剩下 14 種 (不含 neutral)。

再比較不同模型預測評分的準確度，分別用了 R 平方和 RMSE 兩種誤差。使用的模型有 Random Forest、XGB、Gradient Boosting、SVR、Decision Tree 和 KNeighbors Regressor。最後兩種誤差的結果都是 Random Forest Regressor 表現最好，但還是不如預期。

於是再重新歸一化。我們使用了 `f_regression` 的單變數檢定方法，針對每一個情緒特徵計算它與評分之間的 `F-score` 和 `p-value`。`F-score` 代表這個情緒對評分的預測力強度，`p-value` 則表示這個關聯是否具有統計意義。最後保留 `F-score` 超過 50 且 `p-value` 小於 0.01 的情緒，總共有 17 種，作為後續模型訓練的有效特徵。

我們也比較了不同訓練／測試切分比例對模型準確度的影響，發現大多數模型在測試集佔 30% 時表現最佳。最後像前面一樣用了 `R` 平方和 `RMSE` 兩種誤差來比較 5 種模型預測評分的準確度不過卻發現測試為 0.1 時預測分數更高。結果同樣是 `RandomForestRegressor` 表現最好，且比第一次的還要好很多。

2. 新爬蟲後的資料集-20 部電影

載入每部電影的推文情緒資料（`tweet_emotions_all_XXX.csv` 檔案），並合併成一個 `dataframe`。這些資料包含了推文文本、使用者資訊以及 28 種預先分析好的情緒分數。為了確保資料的一致性，我們對電影名稱進行了標準化處理，包括轉換為小寫、移除特殊字元及空格。

接著，我們載入電影評分資料集（`Movie_Ratings_and_BoxOffice.csv`），其中包含了電影的 `IMDb` 評分，並對電影名稱欄位同樣標準化處理，以便匹配前面的資料。接著透過電影名稱欄位將 `IMDb` 評分映射回原本合併後的資料集，也就是新增 `Movie_name` 欄位。在資料清洗階段，我們移除了沒有成功對應到電影評分的推文，並將情緒相關的數值欄位轉換為數值型態，同時處理了這些欄位中的缺失值。

為了提高模型效能，我們進一步對數值特徵進行了離群值檢測與處理，我們使用 `IQR` (`Interquartile Range`) 方法來識別並將離群值替換為 `NaN`，隨後刪除了所有包含 `NaN` 值的行。另外將數據用 `StandardScaler` 進行標準化處理，並將《`Oppenheimer`》、《`Barbie`》、《`avatar2`》這三部電影暫時去除，當作最後的測試資料。

特徵的選擇同樣使用單變數檢定，並根據檢定分數的分布，將篩選標準改為 `f-score` 大於等於 4，`p-value` 小於等於 0.5 的特徵。篩選出的特徵為 `love`、`anger`、`annoyance`、`curiosity`、`confusion`、`desire`、`optimism` 這 7 個。

接著將處理後的資料依 9:1 分成訓練與驗證集，並使用梯度提升、`KNeighbors`、`XGBoost` 隨機森林這 4 種回歸模型訓練，然後以 `R` 平方與 `RMSE` 當作評估指標。

模型測試集的 `R` 平方分數普遍表現不如舊資料集，但我們仍然選用分數最佳的 `Gradient Boosting Regressor` 來預測《`Oppenheimer`》、《`Barbie`》、《`avatar2`》這三部電影的評分。先將三部電影的所有推文用 `groupby` 分組，所有特徵值依據分組取平均後，同樣進行標準化處理後預測，並將預測結果逆標準化以返回原評分範圍，並比較預測與實際結果。

伍、 實驗結果與分析

一、 最終模型的評分預測結果


本研究最終使用 BERT 模型輸出的情緒分數，以下展示分別用全部 20 部電影資料與將 3 部電影獨立成測試集的結果，以 R 平方與 RMSE 作為訓練時的評估指標。可以看到 20 部電影的訓練結果，其最佳模型為 Gradient Boosting，而只有 17 部電影的訓練結果，其分數下降。


原本 20 部電影訓練：

最佳模型 Gradient Boosting 的表現為

RMSE= 0. 2392

$R^2=0.3420$





使用 3 部電影做測試集、17 部電影訓練的結果：

最佳模型仍為 Gradient Boosting，雖然 R 平方分數變很低，但三部電影的測試結果很相近，其表現為：

RMSE= 0.9286


R²=0.1124

```
### 梯度提升迴歸 (Gradient Boosting Regressor)
訓練集 R^2 得分：0.9286
測試集 R^2 得分：0.1124
測試集 RMSE：0.9293
-----

### K 近鄰迴歸 (KNeighbors Regressor)
訓練集 R^2 得分：0.3725
測試集 R^2 得分：0.0418
測試集 RMSE：0.9655
-----

### XGB
訓練集 R^2 得分：1.0000
測試集 R^2 得分：0.0113
測試集 RMSE：0.9807
-----

### 隨機森林迴歸 (Random Forest Regressor)
訓練集 R^2 得分：0.8658
測試集 R^2 得分：0.1064
測試集 RMSE：0.9323
-----
```



選用梯度提升模型預測，下面列出部分電影的實際評分與模型預測值對比：

- Oppenheimer 實際評分為 8.3，模型預測評分為 8.291
- Barbie 實際評分為 6.8，模型預測評分為 7.128
- Avatar2 實際評分為 7.5，模型預測評分為 7.663

Movie_name	Actual_Rating	Predicted_Rating
0 avatar2	7.5	7.662885
1 barbie	6.8	7.127540
9 oppenheimer	8.3	8.291154

— 分組預測整體表現 —
 整體 RMSE (原始單位): 0.2113
 整體 R² 得分: 0.8812



模型在這三部電影上預測誤差皆小於 0.33 分，說明將推文依據電影分組後預測時準確率題高，故 BERT 情緒輸出與評分之間仍存在穩定相關性。代表模型能一定程度上有效擬合實際電影評分，能準確捕捉情緒與電影評分之間的關聯，且誤差控制在合理範圍內。

然而模型分數普遍低落，與用網路資料集相比表現有所落差：

```

### 決策樹迴歸 (Decision Tree Regressor)
訓練集 R^2 得分：0.7623
測試集 R^2 得分：0.7860
測試集 RMSE：0.0007
-----
### 隨機森林迴歸 (Random Forest Regressor)
訓練集 R^2 得分：0.9871
測試集 R^2 得分：0.9247
測試集 RMSE：0.0004
-----
### 梯度提升迴歸 (Gradient Boosting Regressor)
訓練集 R^2 得分：0.8951
測試集 R^2 得分：0.8819
測試集 RMSE：0.0005
-----
### K 近鄰迴歸 (KNeighbors Regressor)
訓練集 R^2 得分：0.9268
測試集 R^2 得分：0.8855
測試集 RMSE：0.0005
-----
### XGB
訓練集 R^2 得分：0.9432
測試集 R^2 得分：0.9048
測試集 RMSE：0.0004
-----

```



比較兩資料集差異，發現前者資料數為約 900 多筆，後者則有 6000 多筆，另外發現我們自己爬到的資料，其離群值很多，經篩選後只剩 200 筆。故兩者差異可能在於資料數以及噪音問題，此網路資料集可能已經果特殊資料處理、篩選。

二、 不同語言模型的情緒分析比較（BERT vs GitHub GloVe 模型）


本研究針對兩種情緒分析模型進行比較：一是基於預訓練語言模型 BERT 所建構的分類器，二是參考 GitHub 上以 GloVe 詞向量搭配 Logistic Regression 的傳統模型。BERT 模型具備 28 類情緒分類能力，能以上下文理解為基礎，細膩區分相似但語義不同的情緒，例如 joy 與 love 或 sadness 與 disappointment。相對地，GitHub 模型僅能辨識 anger、joy、sadness、fear、love、surprise 等 6 類粗略情緒，並以句子中各詞彙的平均向量進行分類，缺乏語境的感知能力。


在情緒分類效能上，BERT 模型因能捕捉語句前後文，對於電影評論中隱含、反諷或複雜表達的情緒具有更高敏感度。在模型預測表現方面，當將兩模型的輸出分數分別作為後續評分預測模型的輸入變項時，BERT 輸出的特徵使得整體模型 R^2 提升約 0.06，RMSE 則下降約 0.11。儘管 BERT 模型在資源需求上較高，但其所帶來的準確率與語意解析力之提升，證實在本研究任務中具明顯優勢。因此，BERT 模型最終成為本研究後續預測階段的主要語言分析基礎。

三、 評分模型優化 (用 BERT 輸出的情緒資料)

1. 不同模型、參數預測評分的準確度比較


本研究嘗試多種機器學習模型（XGBoost、Random Forest、K-Neighbors、Gradient Boosting 等）對 BERT 情緒資料進行訓練，以找出最適合情緒預測電影評分（IMDb Rating）的回歸模型。比較結果如下：





模型	R ²	RMSE
Random Forest	0.3014	0.2465
XGBoost	0.0625	0.2855
Gradient Boosting	0.3420	0.2392
K-Nearest Neighbors	0.1434	0.2729
Decision Tree	0.1577	0.2706


2. 不同情緒的重要程度



從圖中可以看出，不同情緒與實際 IMDb 評分之間存在顯著差異的線性關係：

- i. 正相關情緒：如 **pride**、**relief**、**approval**、**realization** 等與評分呈正相關，代表這些情緒越高，評分傾向越高。
- ii. 負相關情緒：如 **love**、**disapproval**、**caring**、**remorse** 等反而與評分呈負相關，可能因其在高期待卻失望的評論中頻繁出現（如粉絲失望情緒），導致評分偏低。

這項結果反映：某些表面上正向的情緒詞在特定語境中，實際可能代表失落或反諷語氣，因此僅看字面意義會產生誤判。



從圖可知，根據 Random Forest Regressor 模型學習的權重排序，以下幾個情緒對預測評分貢獻最大：



重要性排名前五名依序為：love、amusement、disapproval、confusion、caring

其中，love 雖在 Pearson 相關中呈現負相關，但在實際模型學習過程中因其出現頻率與情緒强度高，仍被視為最關鍵的預測特徵之一。這也說明：在非線性模型中（如隨機森林），某特徵的重要性不等於其單獨相關性，而是與其他特徵交互組合後所能帶來的資訊增益。

此外我們也嘗試了用全部特徵做模型訓練，和挑選後的特徵做模型訓練。

我們採用了單變量線性回歸檢定（univariate regression test）對各個情緒特徵進行初步篩選。使用 SelectKBest(f_regression) 方法，評估每個情緒特徵與目標變數 rating 之間的線性關聯程度。根據檢定結果，僅保留 F 分數大於等於 1 且 p 值小於等於 0.1 的變數，作為具有顯著預測力的情緒指標，並組成精簡後的特徵集 X_new。

為驗證篩選後特徵對模型效能之影響，研究進一步進行完整特徵與精簡特徵的比較。在 Cell 14 中，模型使用原始資料中的所有情緒變數（X_rating_full）進行訓練；而在 Cell 22 中，則改以篩選後的 X_new 為特徵集。兩者皆搭配多種迴歸模型（如隨機森林、梯度提升、K 近鄰等），並透過 R² 與 RMSE 進行效能評估。



由上圖可看出：模型整體效能下降，準確度下降，誤差變大。

我們認為原因是第一，部分被排除的特徵雖然在單變數檢定中不具顯著性，但與其他變數之間可能存在非線性交互作用，過早剔除導致資訊流失。第二，社群平台的情緒分數原本就可能夾雜雜訊與標註偏差，單一特徵難以反映真實意涵，但整體變數群仍可能共同貢獻預測效果。第三，在特徵數量不足的情況下，非線性模型（如 GBDT、隨機森林）難以發揮應有的結構學習能力，進一步影響準確性。

陸、 討論

一、 結果意義

1. 藉由爬蟲所得的電影評論，可預測電影的評分。
2. 比較從評論預測出來的評分，以及真實的評分，看電影評分是否符合群眾的心聲。

二、 研究限制、潛在偏誤

1. 我們的蒐集的電影評論僅有單一平台(X)，可能因資訊來源偏向特定類型的用戶，造成預測結果產生偏誤。推文樣本雖然能反映部分網路聲量與情緒，但並非所有觀眾都會在 Twitter 發表評論，尤其對於不同年齡層或區域的觀影者而言，其網路使用習慣不盡相同，這使得推文數據無法完全代表整體觀眾的觀影體驗與評價。
2. Twitter 上的活躍用戶往往更偏好表達極端情感（特別是強烈正面或負面），中立態度與少量互動者容易被忽略，可能導致模型高估情緒極端群體對票房或評分的影響。再者，推文情緒分類本身依賴預訓練模型判斷，若遇到諷刺、隱喻或語境特殊的推文，情緒得分容易判讀錯誤；這些分類錯誤累積下來，將直接影響後續迴歸模型的輸入品質，進而影響預測結果。
3. 僅蒐集英語評論，雖有助於模型訓練中的情緒分析，卻不一定能代表全世界不同文化背景下的聲音。忽略了各地區差異化票房、市場行銷強度、上映場次等實際影響票房的變數，這些外部因子未被納入模型，使得預測結果可能在某些情況下偏離實際表現。
4. 預測評分時只參考情緒比例，但影響因素可能還有追蹤數、按讚數等等。此外由於使用第三方 API，爬完一定數量的貼文就會被系統偵測並封鎖帳戶，提高資料獲取的困難程度，需要找到更好的解決方式。

三、 改進空間

1. 除了推特，也可以擴及到 IMDb、爛番茄、Metacritic 等國際常見電影平台蒐集評論，但爬蟲的限制較多。將 Facebook、Instagram、Reddit 等社群平台上的影迷互動納入，甚至從 PTT 電影版、Dcard 電影版、YouTube 等來源蒐集，縮減單一平台代表性不足的問題。
2. 蒐集不同語言的資料，但要確認這個語言有完善的訓練資料。每種語言分別訓練後，比較同一部電影中，不同語言評論的情緒比例有何異同。也能納入影片類型、電影製作商(可能有固定粉絲客群)、主要演員口碑、著名影評人評分等特徵，提升模型複雜度與可靠度。
3. 評分也考慮追蹤數、按讚數等因素，將多的權重增加。也可以引入多模態處理，結合文字、圖片甚至影片片段，提升對複雜語意（如諷刺、雙關）的辨識能力。

柒、 結論與未來工作

一、 總結研究發現：

本研究成功建構一個整合 Twitter 爬蟲、BERT 情緒分析與機器學習模型的電影評分預測系統。透過蒐集觀眾在社群媒體上對多部電影的即時評論，並運用預訓練的 BERT 模型抽取出 28 類情緒機率分布，我們進一步利用這些情緒特徵作為迴歸模型的輸入，以預測電影的 IMDb 評分與票房表現。

在評分預測方面，我們實驗比較多種模型，其中以 **Gradient Boosting** 與 **Random Forest** 表現最佳，最高 R^2 約為 **0.34**，顯示社群情緒特徵對觀眾滿意度具有一定預測力。特徵重要性分析亦指出，**joy**、**anger**、**sadness** 為影響電影評分的關鍵情緒變項，對預測準確性具有顯著貢獻。

二、 未來研究的方向：

1. 預測票房

本研究原先目標除了評分預測，也希望進一步預測電影票房表現，藉此探索情緒輿情與實際商業成效之間的關聯。然而在初步實作階段，我們遇到數個困難，導致模型表現不佳，最終未將票房預測納入主模型之中。

具體來說，我們嘗試使用情緒分析結果（如 joy、anger、fear 等 BERT 模型輸出之分數）為特徵，以 Kaggle 公開資料集《enhanced_box_office_data (2000–2024).csv》中提供的 \$Worldwide 欄位作為 target variable。

但情緒與票房關聯不穩定：初步使用 XGBoost、Random Forest、Linear Regression 等模型訓練後，票房預測的 R^2 顯示準確率過低，表示模型幾乎無法解釋票房的變異性，無法捕捉有效關聯。

我們認為這是因為票房高度受外部變數干擾，不同於評分主要反映觀眾觀影後的主觀感受，票房成績更受行銷預算、發行時段、演員陣容、地區發行規模、前期聲量與口碑等多重外部因素影響，而這些變數並未體現在推文資料中。而且情緒變數具非線性與非單調性：舉例來說，anger 和 surprise 等情緒可能在某些話題性強的電影中同時升高，但不一定轉化為高票房。例如一部電影引發大量負評與激烈討論，可能提升評價關注度，卻不等同於購票行為的增加。

未來研究可考慮建立多階段預測鏈（如「電影熱度 → 評分預測 → 票房估計」）或採用時間序列模型捕捉評論發布與票房波動間的動態關係。

2. 納入更多資訊

目前模型表現雖優於基線，但 R^2 僅達約 0.3，顯示情緒特徵僅能部分解釋評分變異。未來可考慮納入推文的其它資訊（如按讚數、分享數）與使用者的帳號屬性（例如追蹤者數、是否為公開帳號等）以強化模型。

3. 納入更多平台

除了 Twitter，尚有 IMDb、Reddit、Rotten Tomatoes、PTT、Dcard、YouTube 等評論來源。未來可跨平台整合不同語言、文化與社群結構之評論，以提升模型的普適性與多元語境適應力。

4. 區域市場分析

情緒與評分之關聯可能因地區文化與市場差異而不同。未來可將資料依地區或語言群體切割，進行區域性模型訓練與比較，檢驗情緒與評分的關係在不同市場中的穩定性與適用性。

5. 提升語意理解模型效能

除了 BERT，未來亦可測試更大型語言模型（如 RoBERTa、GPT-based encoder、DeBERTa），以進一步提升情緒分類的準確性與對評分的預測能力。

捌、 Acknowledgements（致謝）

指導老師：何承遠

組員分工表：

組員	程式	書面報告	口頭報告
周知顯	1. 尋找情緒分析可參考程式 (Emotion Pred. App) 2. 爬蟲與情緒分析的程式開發與驗證 3. 蒐集預測電影評分系統的資料，並處理成可訓練之資料集	三、資料說明 四、研究方法：1. 爬蟲	方法-爬蟲
盧仁宇	增加爬蟲程式的篩選條件&輸入關鍵字功能、將其與情緒分析程式合併(一條龍流程)、爬蟲擷取電影貼文與蒐集 ground truth 資料	零、摘要 一、簡介 六、討論	討論與未來展望
曾鈺淇	完善評分模型，將資料集分別進行預處理，訓練模型並顯示分數、預測結果。	五、實驗結果與分析	結果

周芷茵	評分模型初版建構	五、實驗結果與分析 七、結論與未來工作	結果
許珈寧	改情緒分析所使用的模型（後未採納）、嘗試使用 Emotion Prediction App 去分析（但沒成功）	一、簡介 二、相關文獻探討的 2 (bert 模型) 四、研究方法的 2 (情緒分析)	開頭簡介
胡馨云		二、相關文獻探討的 1 四、研究方法的 1 六、討論 將大家寫的整理到 word 檔	方法 - 情緒分析、評分預測

玖、 參考文獻

1. Chanda, D. (n.d.). *GoEmotions* [Data set]. Kaggle. <https://www.kaggle.com/datasets/debarshichanda/goemotions/data>
2. Rakeshsahni. (n.d.). *Emotion prediction* [GitHub repository]. GitHub. <https://github.com/rakeshsahni/emotion-prediction>
3. NVIDIA. (n.d.). *PyTorch*. <https://www.nvidia.cn/glossary/pytorch/>
4. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of deep bidirectional transformers for language understanding* [Preprint]. arXiv. <https://arxiv.org/abs/1810.04805>